Statisztika a közösségi média használatról

Forrása az adathalmaznak: https://www.kaggle.com/datasets/imyjoshua/average-time-spent-by-a-user-on-social-media?resource=download

Forráskódok és Github repository: https://github.com/niklierik/szamitogepes-statisztika-beadando

Leíró statisztika

Forráskód: 1_leiro.r

Kvantitatív összegzés

	Kor	Eltöltött idő (óra/nap)	Bevétel (USD)
Minimum	18.000	1.000	10012.00
Maximum	64.000	9.000	19980.00
Átlag	40.986	5.029	15014.82
Q1 (25%)	29.000	3.000	12402.25
Medián / Q2 (50%)	42.000	5.000	14904.50
Q3 (75%)	52.000	7.000	17674.25

Boxplotok

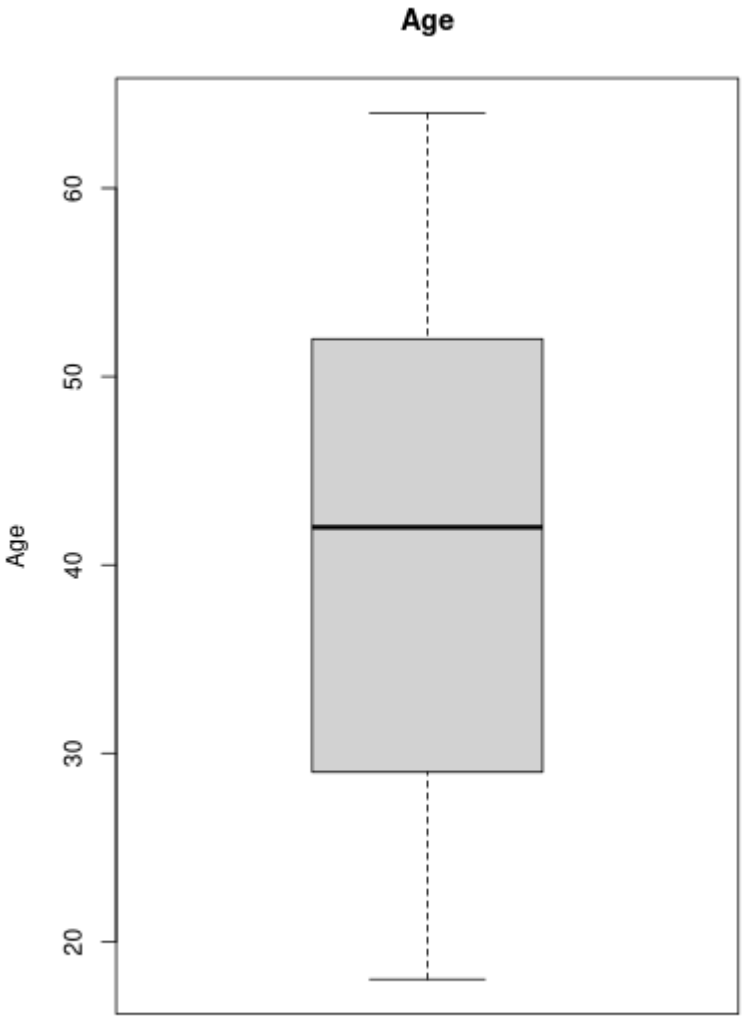
Age
Age
20
30
40
50
60

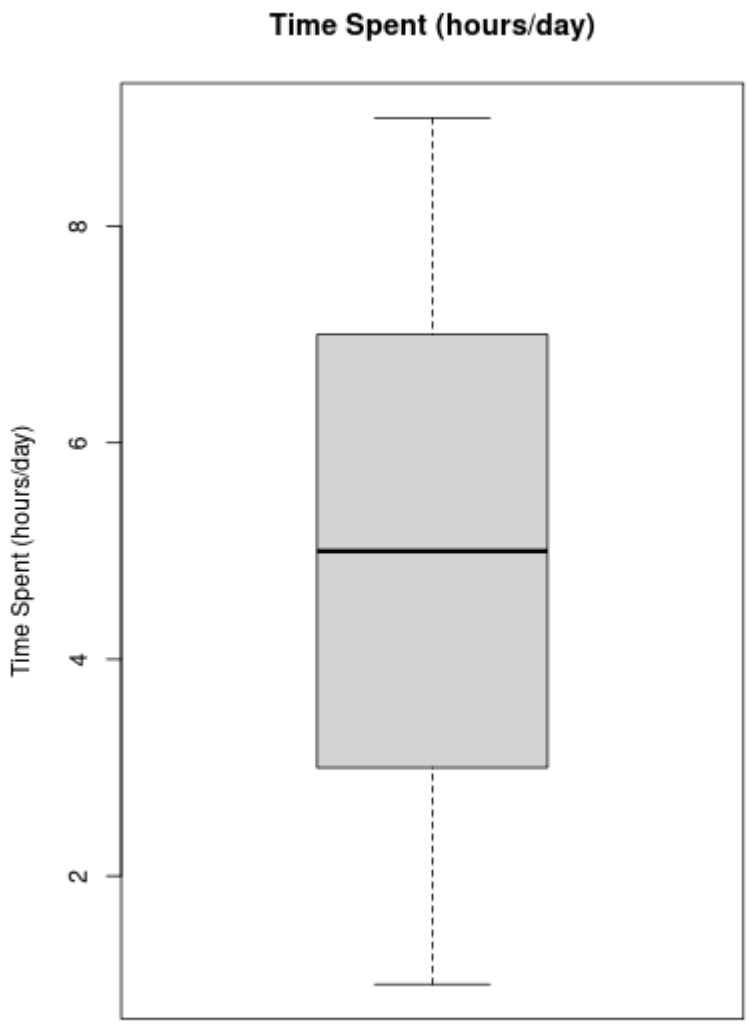
Time Spent (hours/day)
Time Spent (hours/day)
2
4
6
8

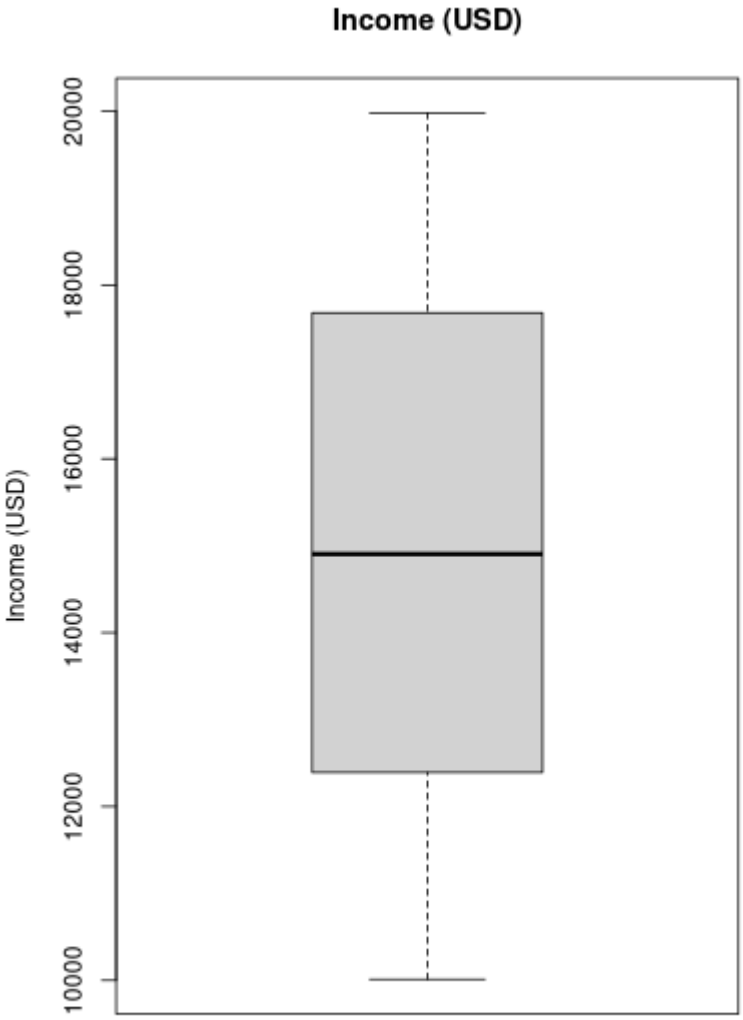

Kvalitatív összegzés

Nem / Közösségi Média Platform

	Facebook	Instagram	YouTube
Nő	85	135	111
Férfi	113	128	96
Nem-Bináris	109	100	123

Hisztogrammok

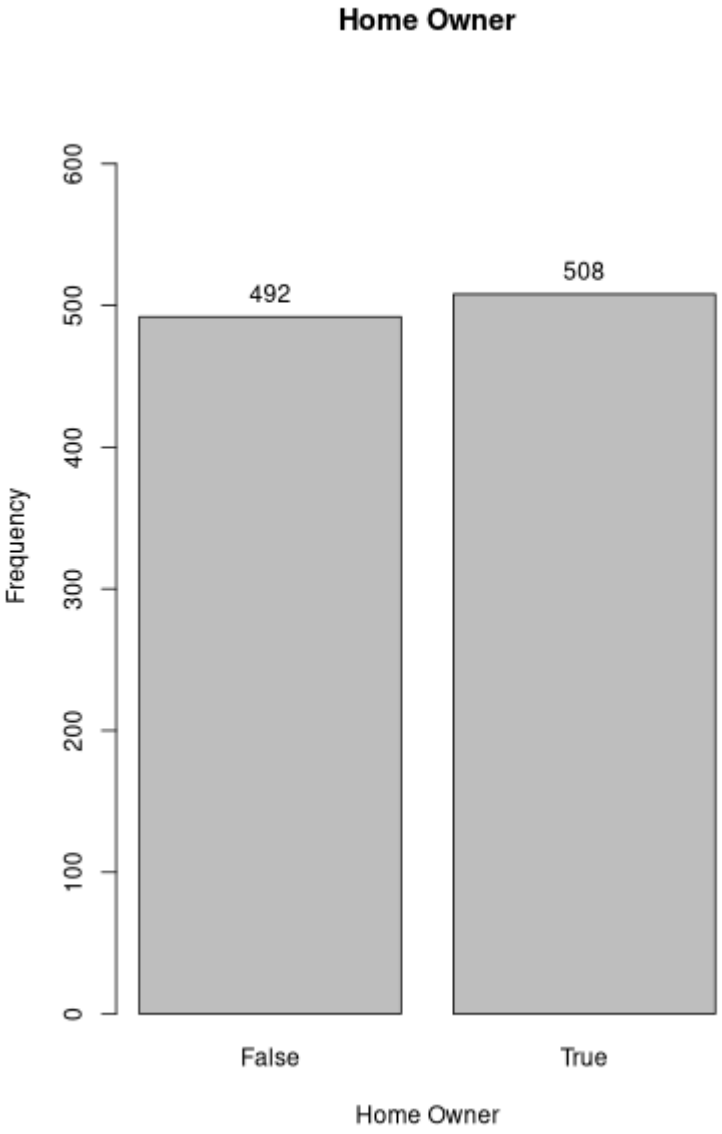
Home Owner
Frequency
0
100
200
300
400
500
600
492
508
False
True
Home Owner

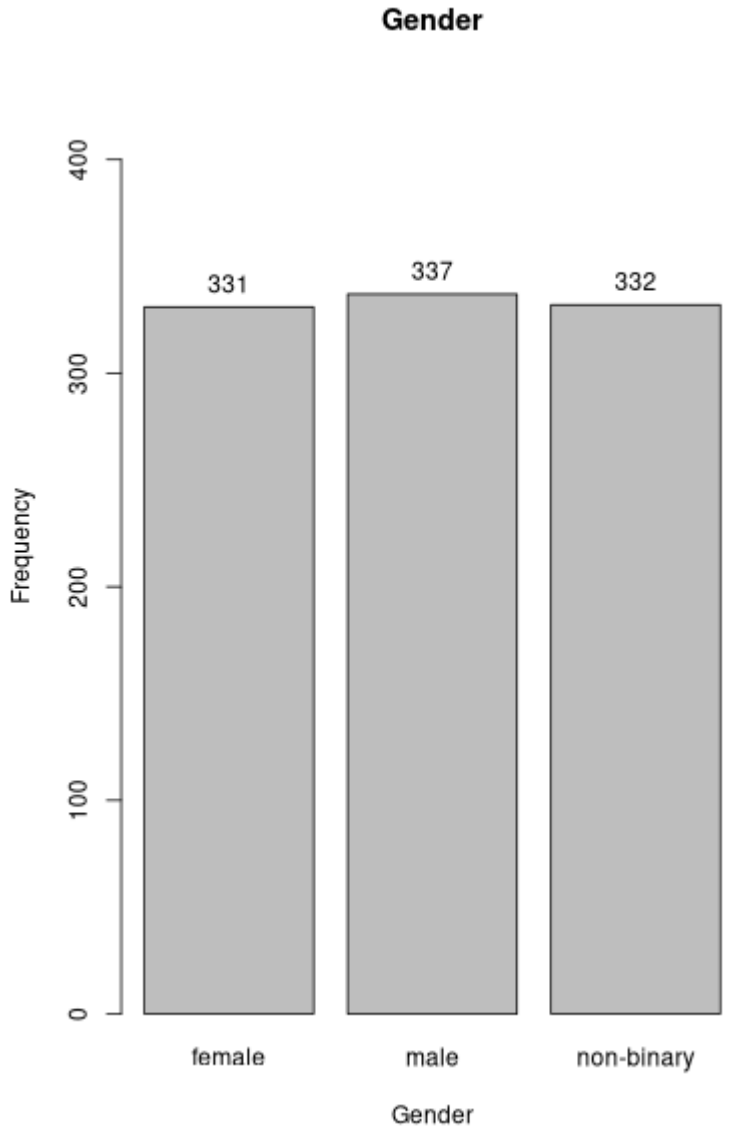
Gender
Frequency
0
100
200
300
400
331
337
332
female
male
non-binary
Gender

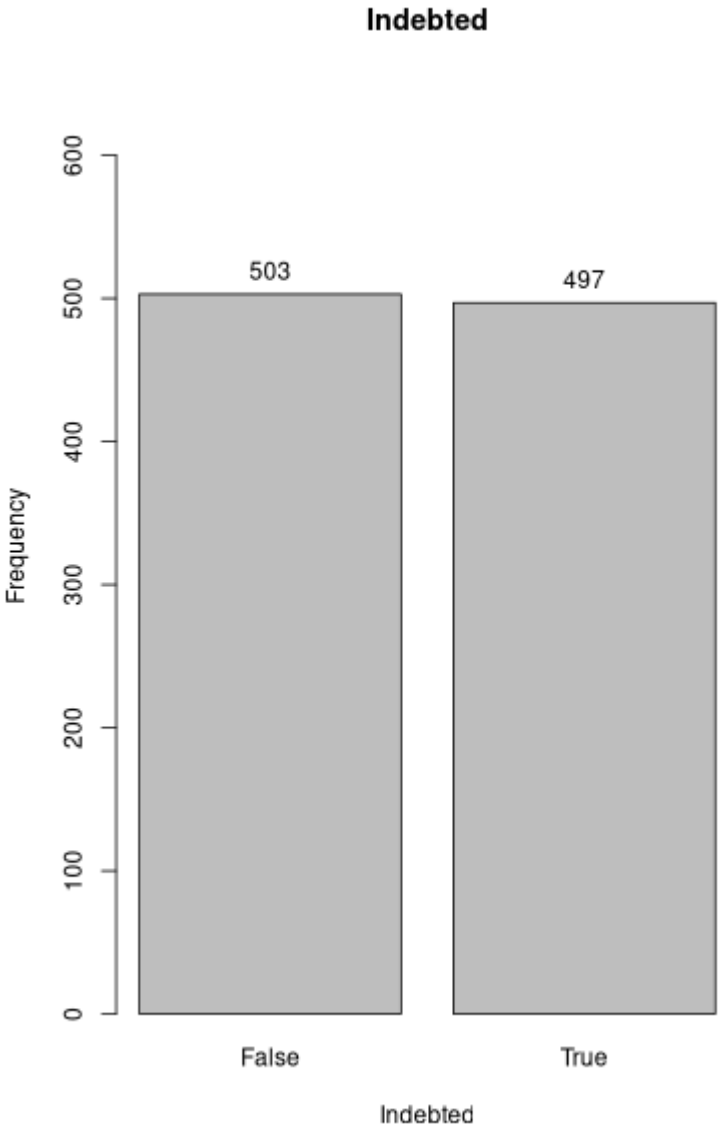
Indebted
Frequency
0
100
200
300
400
500
600
503
497
False
True
Indebted

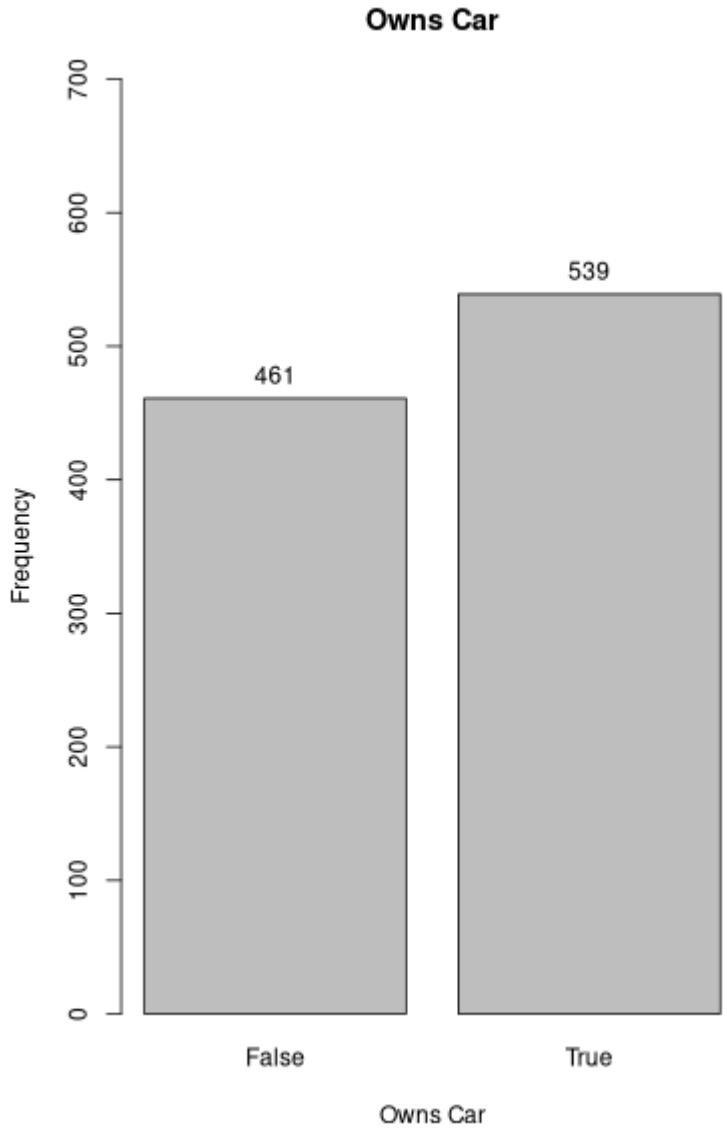
Owns Car
Frequency
0
100
200
300
400
500
600
700
461
539
False
True
Owns Car

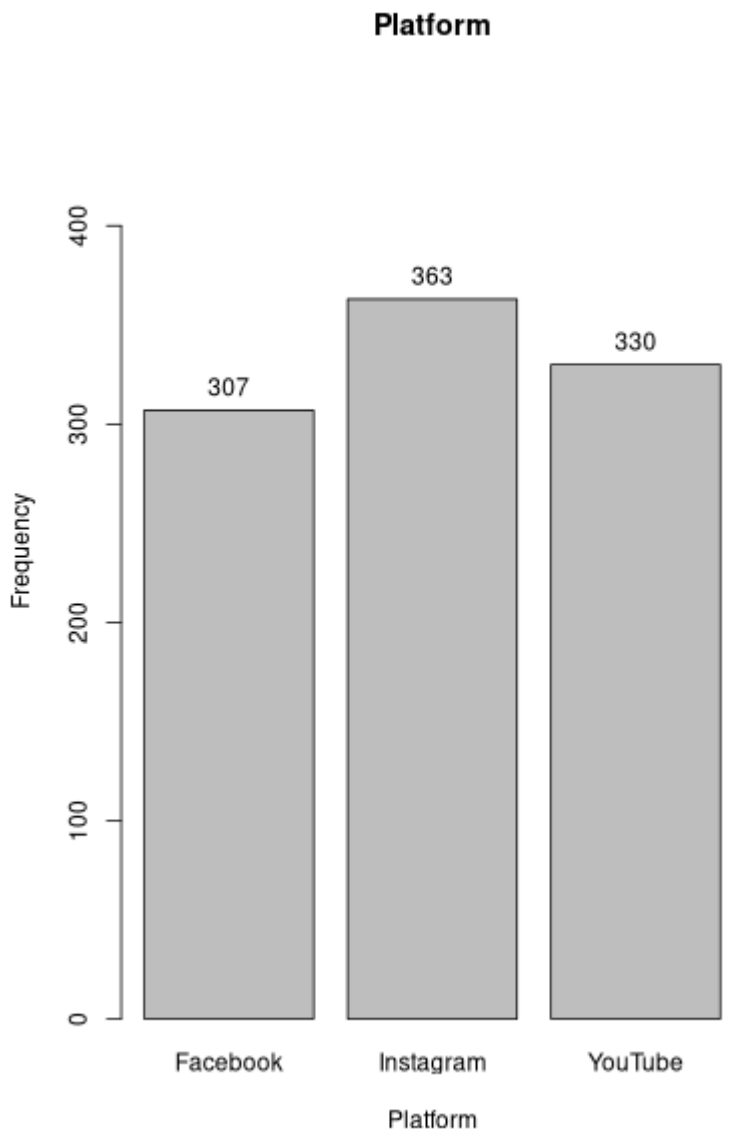

2. Közösségi médián töltött idő férfiak és nők között (kétmintás t-próba)

Forráskód: [2_t_proba.r]

Átlagos eltöltött idő

- **Férfiaknál**: 4.821958
- **Nőnél**: 5.190332

Null-hipotézis (H0)

Nincs jelentős különbség az átlagos időtöltésben a férfiak és nők között.

H_0: μ_férfi = μ_nő , ahol μ az átlagot jelöli.

Null-hipotézis eredménye

```
t = -1.8618
df = 665.24
p-value = 0.06307
```

Mivel a p-érték 0.05-nől nagyobb, ezért nem tudjuk elutasítani a null-hipotézist. Esetleg azt az alternatív hipotézist megfogalmazhatjuk:

Alternatív hipotézis (H1)

Van jelentős különbség az átlagos időtöltésben a férfiak és nők között.

Azonban ezt a próba ténylgesen nem bizonyítja.

3. A nem és platform változók összefüggése (Chi négyzet próba)

Forráskód: [3_khi_negyzet_proba.r]

Kontingencia tábla nem és platform között:

	Facebook	Instagram	YouTube
Nő	85	135	111
Férfi	113	128	96
Nem-Bináris	109	100	123

Khí-négyzet próba eredménye:

```
X-squared = 13.436
df = 4
p-value = 0.009331
```

Null-hipotézis (H0)

A nem és platform függetlenek egymástól.

Null-hipotézis eredménye

A p-érték kisebb, mint 0.05, ezért elutasítjuk a nullhipotézist. Ez miatt biztosra mondható, hogy a nemtől függ milyen platformon töltenek el a felhasználók időt.

4. Lineáris regresszió eltöltött időre a bevétel és a kor alapján

Forráskód: [4_lin_regresszio.r]

```
Modell 1: time_spent ~ age

Call:
lm(formula = time_spent ~ age, data = data_set)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.1625 -2.0734 -0.0448  2.0220  4.1174 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept)  5.289674   0.256660  20.610   <2e-16 ***
age         -0.006360   0.005948  -1.069    0.285    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.538 on 998 degrees of freedom
Multiple R-squared:  0.001144,	Adjusted R-squared:  0.0001434 
F-statistic: 1.143 on 1 and 998 DF,  p-value: 0.2852

R-squared: 0.001144263
AIC: 4704.353

Modell 2: time_spent ~ income

Call:
lm(formula = time_spent ~ income, data = data_set)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.0492 -2.0372 -0.0258  1.9796  3.9914 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept) 4.968e+00  4.155e-01   11.96   <2e-16 ***
income      4.081e-06  2.715e-05    0.15    0.881    
---
```

```
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.539 on 998 degrees of freedom
Multiple R-squared:  2.263e-05, Adjusted R-squared:  -0.0009793
F-statistic: 0.02259 on 1 and 998 DF,  p-value: 0.8806

R-squared: 2.263144e-05
AIC: 4705.476

Modell 3: time_spent ~ age + income

Call:
lm(formula = time_spent ~ age + income, data = data_set)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.1695 -2.0736 -0.0454  2.0194  4.1224 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept)  5.265e+00  5.014e-01  10.501   <2e-16 ***
age         -6.330e-03  5.974e-03  -1.060    0.290    
income       1.557e-06  2.725e-05   0.057    0.954    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.539 on 997 degrees of freedom
Multiple R-squared:  0.001148,  Adjusted R-squared:  -0.0008562 
F-statistic: 0.5727 on 2 and 997 DF,  p-value: 0.5642

R-squared: 0.001147532
AIC: 4706.35

Összehasonlítás:
Model 1 R-squared: 0.001144263 AIC: 4704.353
Model 2 R-squared: 2.263144e-05 AIC: 4705.476
Model 3 R-squared: 0.001147532 AIC: 4706.35
```

Ábrák

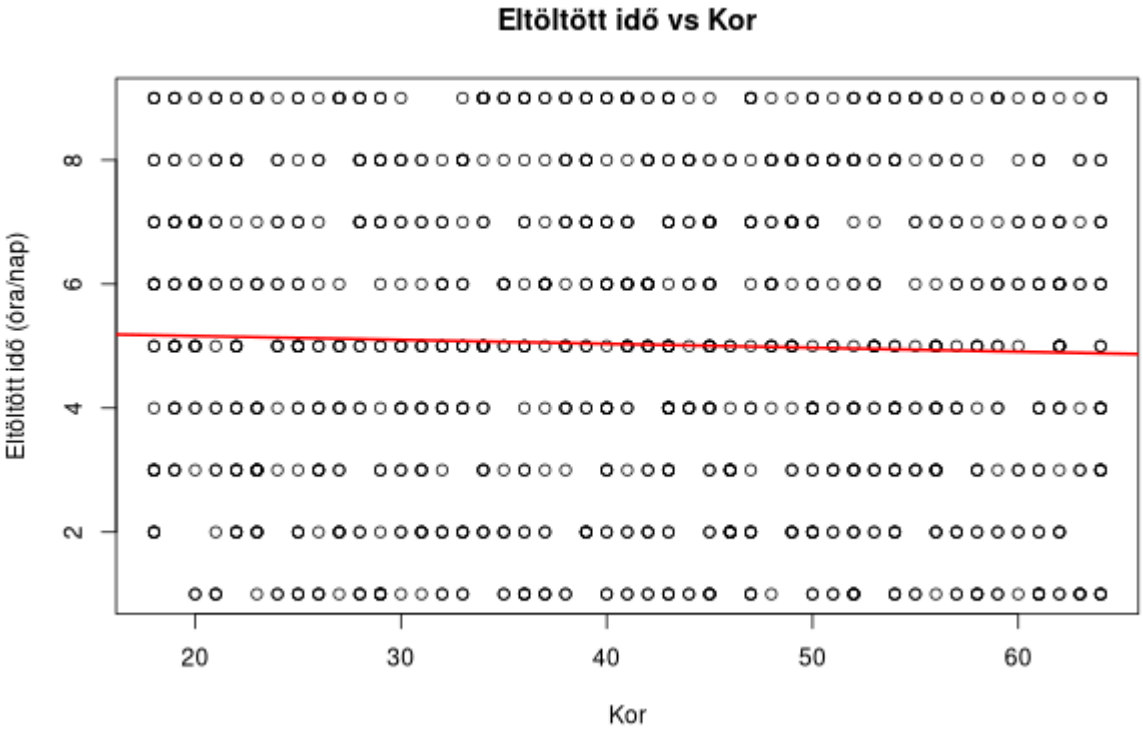
Eltöltött idő vs Kor
Eltöltött idő (óra/nap)
2
4
6
8
20
30
40
50
60
Kor

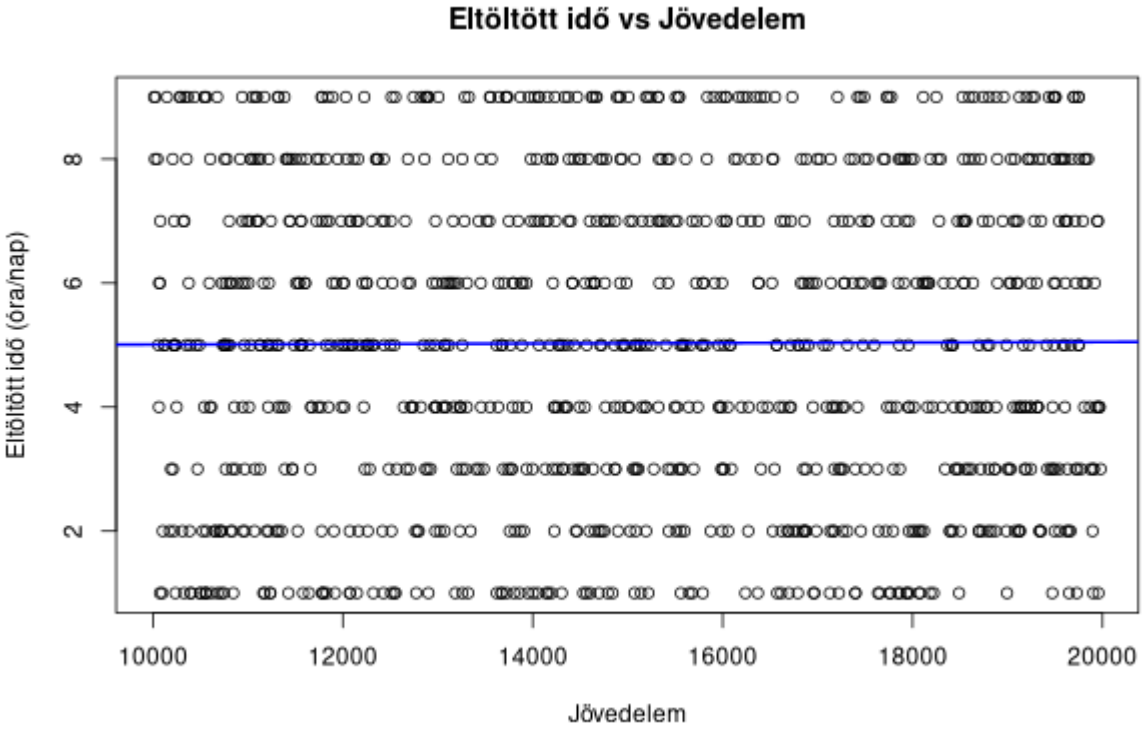
Eltöltött idő vs Jövedelem
Eltöltött idő (óra/nap)
2
4
6
8
10000
12000
14000
16000
18000
20000
Jövedelem

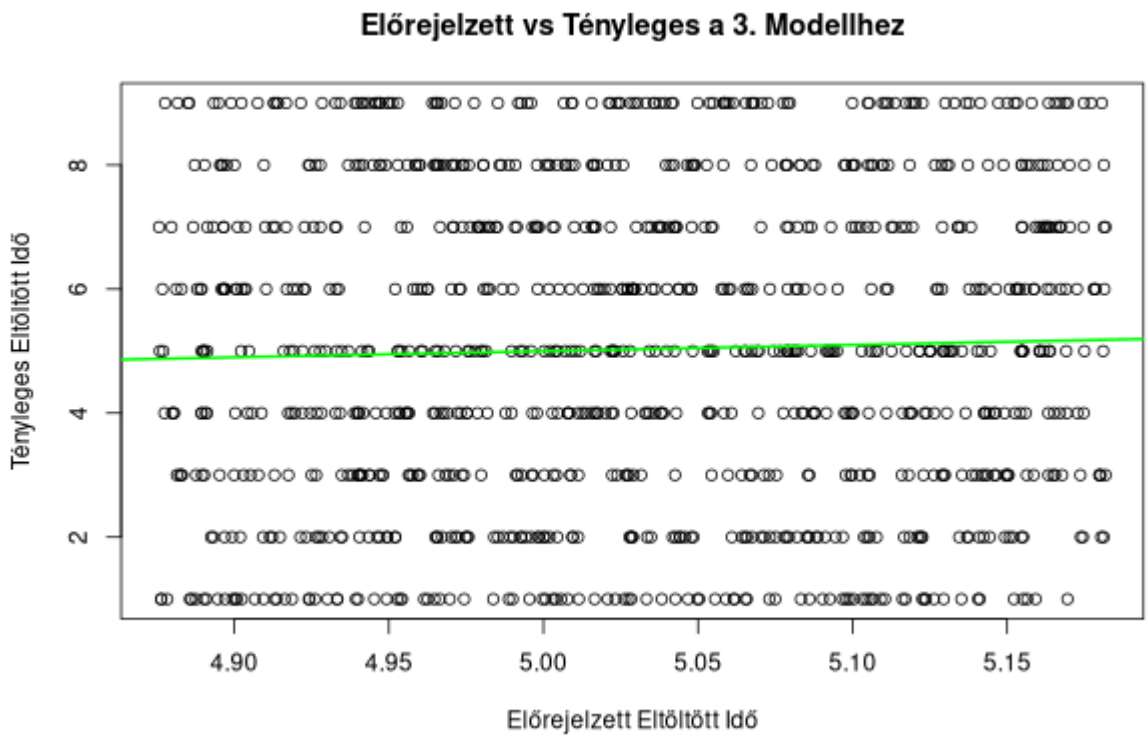

Legjobb modell?

- R^2 alapján a harmadik (ez a legnagyobb R^2 értékű)
- AIC alapján az első (ez a legkisebb AIC értékű)

5. Nemlineáris regresszió a platformon eltöltött idő megbecslésére kor alapján

Forráskód: [5_nemlin_regresszio.r]

```
Nemlineáris regresszió modell (kvadratikus):

Call:
lm(formula = time_spent ~ poly(age, 2), data = train_data)

---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.539 on 996 degrees of freedom
Multiple R-squared:  0.001189,  Adjusted R-squared:  -0.0008168
F-statistic: 0.5928 on 2 and 996 DF,  p-value: 0.553
```

Coefficients

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	5.03103	0.08034	62.621	<2e-16 ***
poly(age, 2)1	-2.64353	2.53933	-1.041	0.298
poly(age, 2)2	-0.81012	2.53933	-0.319	0.750

Residuals

Min	1Q	Median	3Q	Max
-4.1236	-2.0953	-0.0707	2.0015	4.1672

Predikció

- Tényleges érték: 3
- Előrejelzett érték: 4.92974
- Abszolút eltérés: 1.92974

Ábra

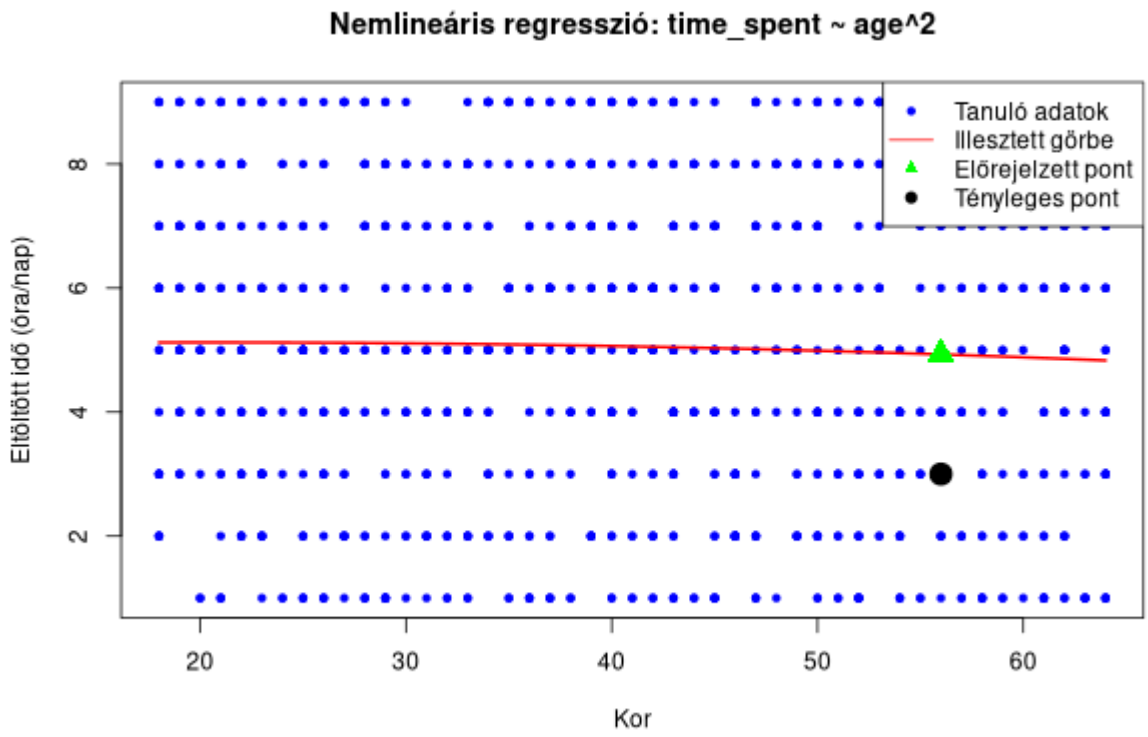

6. Faktor analízis

Forráskód: [6_faktor_analizis.r]

Folytonos változók: kor (age), naponta eltöltött idő órában (time_spent), bevétel USD-ben (income)

Eredmény

```
Faktor analízis eredménye (1 faktor):

Call:
factanal(x = continuous_vars, factors = 1)

The degrees of freedom for the model is 0 and the fit was 0
```

Uniquenesses

age	time_spent	income
0.380	0.998	0.988

Loadings

	Factor1
age	0.787
time_spent	
income	-0.111
SS loadings	0.634
Proportion Var	0.211

Faktor loadings

age	time_spent	income
0.78727289	-0.04296642	-0.11100467

Értelmezés

Ha az érték 0.5 felett van, akkor jól magyarázza

- Kor: jól magyarázza
- Eltöltött idő: rosszul magyarázza
- Jövedelem: rosszul magyarázza

Ábra

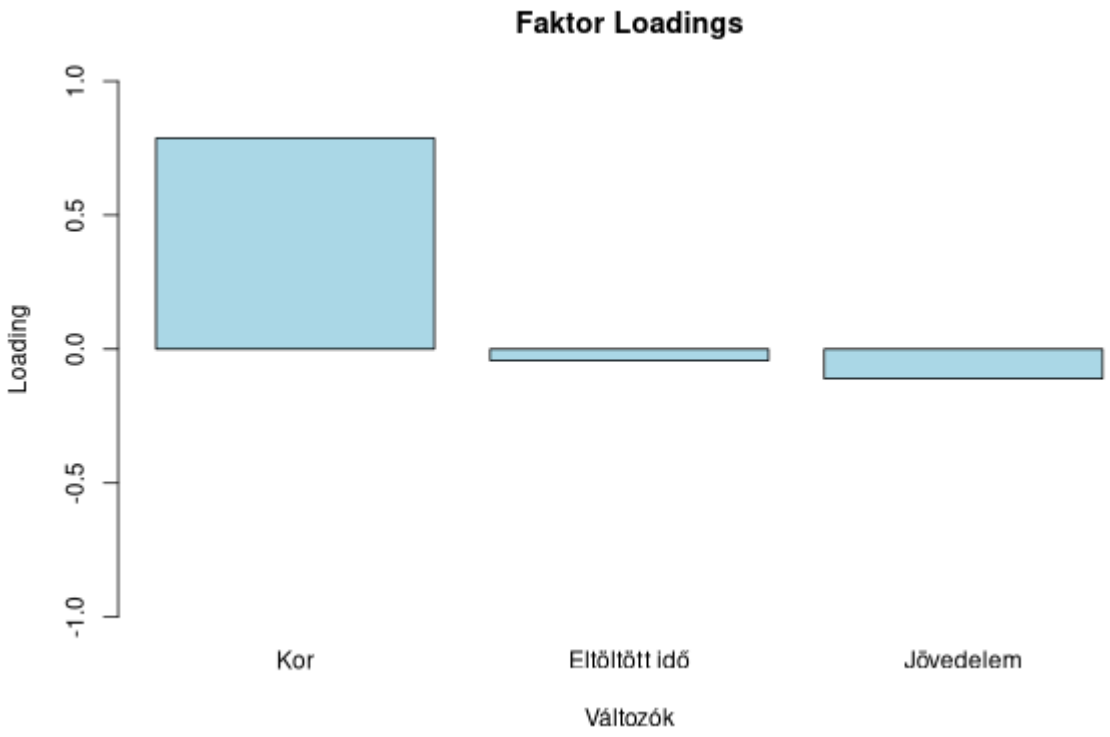

7. K-means-szel osztályozni az eltöltött időt (óra/nap) kor alapján

Output

```
Automatikusan kiválasztott optimális klaszterek száma: k = 9 (ahol a hiba
csökkenése lelassul)

K-means klaszterezés eredménye (k = 9 ):

A csoportok átlagos értékei (középpontok):
       age time_spent
1 43.76000   4.456000
```

```
2 39.11321   6.273585
3 53.73529   7.823529
4 33.53043   4.460870
5 49.07547   5.018868
6 20.57931   5.365517
7 27.21094   4.781250
8 55.27473   2.879121
9 61.73276   4.982759

Minden csoportba hány pont tartozik:
[1] 125 106  68 115 106 145 128  91 116
Összes hiba a csoportosításban: 8329.838 (alacsonyabb = jobb)
```

Ábrák

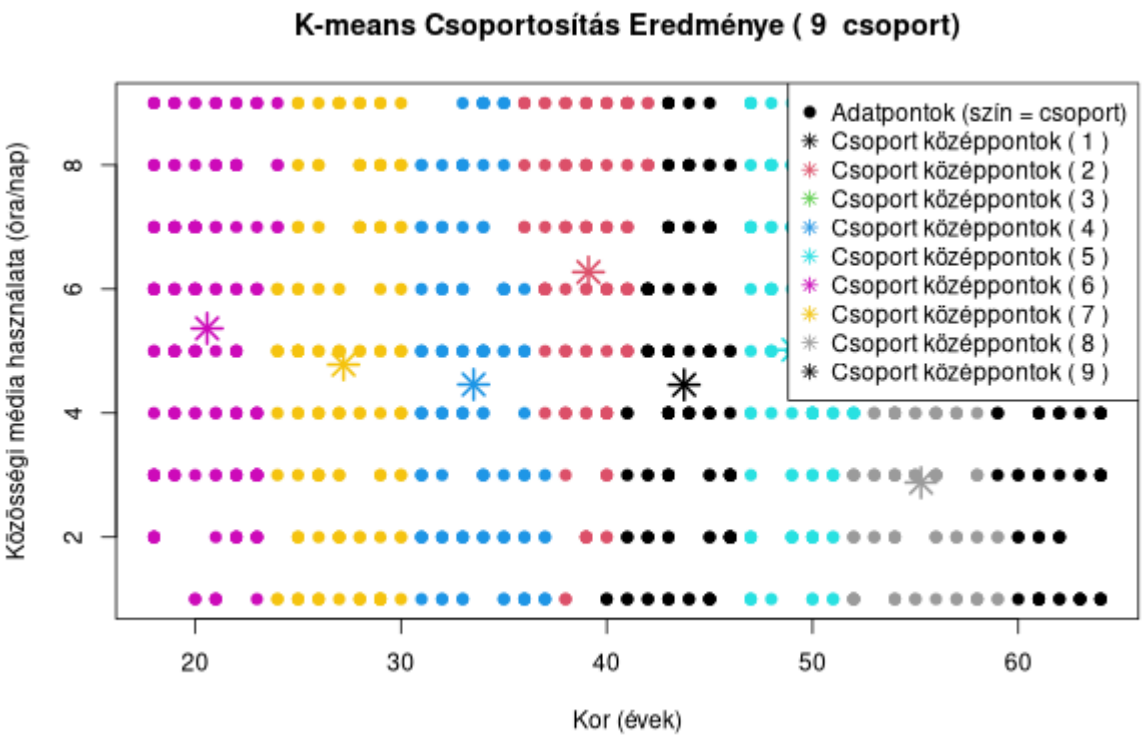
K-means Csoportosítás Eredménye (9 csoport)
Adatpontok (szín = csoport)
Csoport középpontok (1)
Csoport középpontok (2)
Csoport középpontok (3)
Csoport középpontok (4)
Csoport középpontok (5)
Csoport középpontok (6)
Csoport középpontok (7)
Csoport középpontok (8)
Csoport középpontok (9)
Közösségi média használata (óra/nap)
2
4
6
8
20
30
40
50
60
Kor (évek)

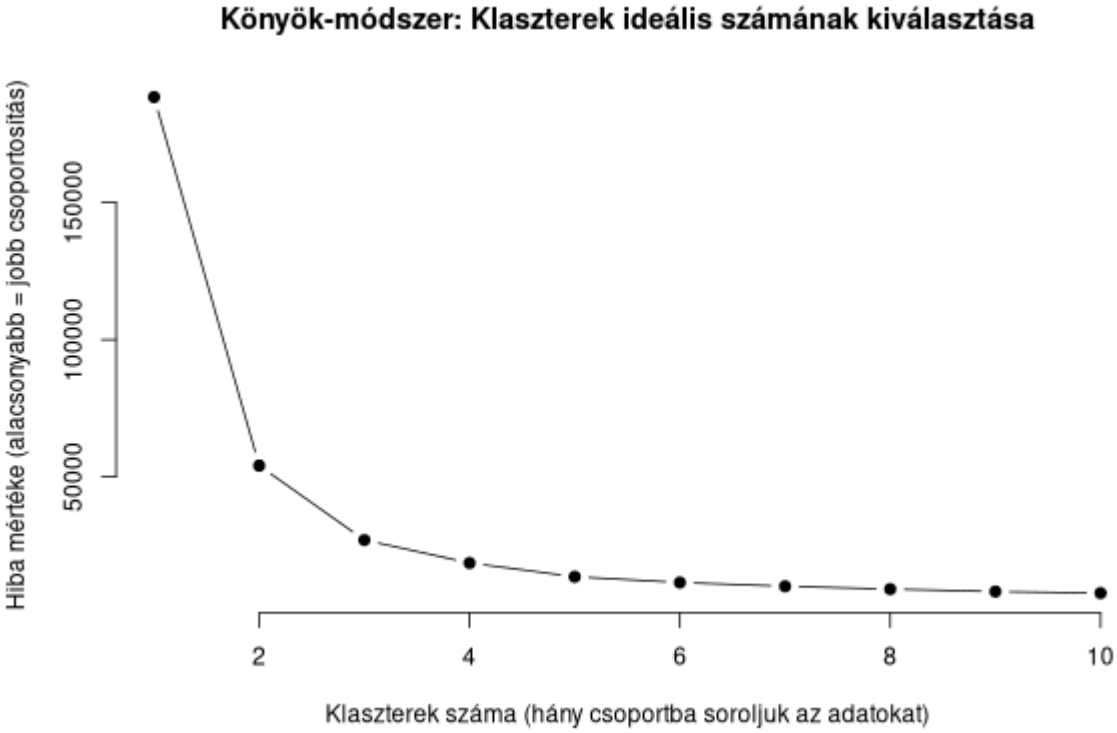
Könyök-módszer: Klaszterek ideális számának kiválasztása
Hiba mértéke (alacsonyabb = jobb csoportosítás)
50000
100000
150000
2
4
6
8
10
Klaszterek száma (hány csoportba soroljuk az adatokat)